

Pandas

What is Pandas?

Pandas는 표 형태 데이터를 다루기 위한 Python 라이브러리

country	year	pop	continent	lifeExp	gdpPercap
Czech Republic	1972	9862158.0	Europe	70.29	13108.4536
Czech Republic	1977	10161915.0	Europe	70.71	14800.160619999999
Czech Republic	1982	10303704.0	Europe	70.96	15377.22855
Czech Republic	1987	10311597.0	Europe	71.58	16310.4434
Czech Republic	1992	10315702.0	Europe	72.4	14297.021219999999
Czech Republic	1997	10300707.0	Europe	74.01	16048.51424
Czech Republic	2002	10256295.0	Europe	75.51	17596.210219999997
Czech Republic	2007	10228744.0	Europe	76.486	22833.30851
Denmark	1952	4334000.0	Europe	70.78	9692.385245
Denmark	1957	4487831.0	Europe	71.81	11099.65935

example

Why do we use Pandas?

데이터를 빠르게 확인하고, 필요한 부분만 선택하고, 조건에 맞게 분석할 수 있기 때문이다.

Example

- 성적이 80점 이상인 학생만 찾기
- 과목별 평균 점수 구하기
- 비어 있는 값 처리하기
- CSV 파일 불러오기
- 여러 표를 하나로 합치기
- 대회 나가기

How to use Pandas?

Terminal을 열어서 아래 명령어를 실행.

```
pip install pandas
```

Vscode에서 아래코드 실행

```
import pandas as pd

# read_csv(): CSV 파일을 읽어서 DataFrame으로 가져옴
df = pd.read_csv("pandas_students_analysis.csv")
```

"pandas_students_analysis.csv"는 웹페이지에 있음!!

How to understand the dataset

```
import pandas as pd

# read_csv(): CSV 파일을 읽어서 DataFrame으로 가져옴
df = pd.read_csv("pandas_students_analysis.csv")

print("Shape:")
print(df.shape)
# shape: 데이터의 행(row)과 열(column) 개수 확인 → 데이터 크기 파악

print("\nColumns:")
print(df.columns)
# columns: DataFrame의 열 이름 확인 → 어떤 정보가 있는지 파악

print("\nInfo:")
df.info()
# info(): 각 열의 데이터 타입과 결측치 개수 확인 → 데이터 구조 파악

print("\nSummary:")
print(df.describe())
# describe(): 수치형 데이터의 통계 요약 제공 → 평균, 표준편차, 최솟값, 최댓값 파악
```

How to select and filter data

```
import pandas as pd

df = pd.read_csv("pandas_students_analysis.csv")

print("Select columns:")
print(df[["name", "class", "math", "english", "science"]].head())
# df[["col1", "col2"]]: 여러 열 선택 → 필요한 정보만 보기
# head(): 위에서부터 5개 행 출력 → 데이터 미리보기

print("\nFilter students with math score >= 80:")
high_math = df[df["math"] >= 80]
# df["math"] >= 80: math 점수가 80 이상인지 True/False로 판단
# df[조건]: 조건이 True인 행만 선택 → 조건 필터링

print(high_math[["name", "class", "math"]])
```

How to clean missing values

```
import pandas as pd

df = pd.read_csv("pandas_students_analysis.csv")

print("Missing values before cleaning:")
print(df.isna().sum())
# isna(): 결측치이면 True 반환
# sum(): True의 개수를 합산 → 열별 결측치 개수 확인

df["math"] = df["math"].fillna(df["math"].mean())
# mean(): 평균값 계산
# fillna(): 결측치를 특정 값으로 채움 → 여기서는 평균값으로 대체

df["english"] = df["english"].fillna(df["english"].mean())
df["study_hours"] = df["study_hours"].fillna(df["study_hours"].mean())
df["attendance_rate"] = df["attendance_rate"].fillna(df["attendance_rate"].mean())

print("\nMissing values after cleaning:")
print(df.isna().sum())
```

How to create new columns

```
import pandas as pd

df = pd.read_csv("pandas_students_analysis.csv")

df["math"] = df["math"].fillna(df["math"].mean())
df["english"] = df["english"].fillna(df["english"].mean())
df["study_hours"] = df["study_hours"].fillna(df["study_hours"].mean())
df["attendance_rate"] = df["attendance_rate"].fillna(df["attendance_rate"].mean())

df["total_score"] = df["math"] + df["english"] + df["science"]
# 새로운 열 만들기: df["new_column"] = 계산식
# total_score: 세 과목 점수의 합계

df["average_score"] = df["total_score"] / 3
# average_score: 총점을 과목 수로 나누어 평균 점수 계산

df["pass"] = df["average_score"] >= 80
# 비교 연산 결과는 True/False로 저장됨 → 합격 여부 판단

print(df[["name", "total_score", "average_score", "pass"]].head())
```


How to make grades

```
import pandas as pd

df = pd.read_csv("pandas_students_analysis.csv")

df["math"] = df["math"].fillna(df["math"].mean())
df["english"] = df["english"].fillna(df["english"].mean())
df["study_hours"] = df["study_hours"].fillna(df["study_hours"].mean())
df["attendance_rate"] = df["attendance_rate"].fillna(df["attendance_rate"].mean())

df["total_score"] = df["math"] + df["english"] + df["science"]
df["average_score"] = df["total_score"] / 3

def make_grade(score):
    if score >= 90:
        return "A"
    elif score >= 80:
        return "B"
    elif score >= 70:
        return "C"
    else:
        return "D"

df["grade"] = df["average_score"].apply(make_grade)
# apply(): 각 데이터에 함수를 하나씩 적용 → 평균 점수를 등급으로 변환

print(df[["name", "average_score", "grade"]].head(10))
```

How to summarize data

```
import pandas as pd

df = pd.read_csv("pandas_students_analysis.csv")

df["math"] = df["math"].fillna(df["math"].mean())
df["english"] = df["english"].fillna(df["english"].mean())
df["study_hours"] = df["study_hours"].fillna(df["study_hours"].mean())
df["attendance_rate"] = df["attendance_rate"].fillna(df["attendance_rate"].mean())

df["total_score"] = df["math"] + df["english"] + df["science"]
df["average_score"] = df["total_score"] / 3

print(df[["math", "english", "science", "study_hours", "attendance_rate", "average_score"]].describe())
# describe(): 수치형 데이터의 통계 요약 제공
# count: 데이터 개수
# mean: 평균
# std: 표준편차
# min: 최솟값
# max: 최댓값
```

How to summarize data

```
import pandas as pd

df = pd.read_csv("pandas_students_analysis.csv")

df["math"] = df["math"].fillna(df["math"].mean())
df["english"] = df["english"].fillna(df["english"].mean())
df["study_hours"] = df["study_hours"].fillna(df["study_hours"].mean())
df["attendance_rate"] = df["attendance_rate"].fillna(df["attendance_rate"].mean())

df["total_score"] = df["math"] + df["english"] + df["science"]
df["average_score"] = df["total_score"] / 3

print(df[["math", "english", "science", "study_hours", "attendance_rate", "average_score"]].describe())
# describe(): 수치형 데이터의 통계 요약 제공
# count: 데이터 개수
# mean: 평균
# std: 표준편차
# min: 최솟값
# max: 최댓값
```

How to compare study groups

```
import pandas as pd

df = pd.read_csv("pandas_students_analysis.csv")

df["math"] = df["math"].fillna(df["math"].mean())
df["english"] = df["english"].fillna(df["english"].mean())
df["study_hours"] = df["study_hours"].fillna(df["study_hours"].mean())
df["attendance_rate"] = df["attendance_rate"].fillna(df["attendance_rate"].mean())

df["total_score"] = df["math"] + df["english"] + df["science"]
df["average_score"] = df["total_score"] / 3

def study_level(hours):
    if hours >= 6:
        return "High"
    elif hours >= 4:
        return "Middle"
    else:
        return "Low"

df["study_level"] = df["study_hours"].apply(study_level)
# apply(): 각 행의 값에 함수를 하나씩 적용
# study_hours 값을 High, Middle, Low 그룹으로 변환

study_summary = df.groupby("study_level")["average_score"].mean()
# groupby(): 특정 기준으로 데이터를 그룹화
# mean(): 각 그룹의 평균 계산

print(study_summary)
```

How to compare absence groups

```
import pandas as pd

df = pd.read_csv("pandas_students_analysis.csv")

df["math"] = df["math"].fillna(df["math"].mean())
df["english"] = df["english"].fillna(df["english"].mean())
df["study_hours"] = df["study_hours"].fillna(df["study_hours"].mean())
df["attendance_rate"] = df["attendance_rate"].fillna(df["attendance_rate"].mean())

df["total_score"] = df["math"] + df["english"] + df["science"]
df["average_score"] = df["total_score"] / 3

def absence_level(count):
    if count >= 5:
        return "Many"
    elif count >= 2:
        return "Some"
    else:
        return "Few"

df["absence_level"] = df["absence_count"].apply(absence_level)
# absence_count를 Few, Some, Many 그룹으로 나눔

absence_summary = df.groupby("absence_level")["average_score"].mean()
# 결석 그룹별 평균 점수 계산

print(absence_summary)
```

How to find top and bottom students

```
import pandas as pd

df = pd.read_csv("pandas_students_analysis.csv")

df["math"] = df["math"].fillna(df["math"].mean())
df["english"] = df["english"].fillna(df["english"].mean())
df["study_hours"] = df["study_hours"].fillna(df["study_hours"].mean())
df["attendance_rate"] = df["attendance_rate"].fillna(df["attendance_rate"].mean())

df["total_score"] = df["math"] + df["english"] + df["science"]
df["average_score"] = df["total_score"] / 3

sorted_df = df.sort_values("average_score", ascending=False)
# sort_values(): 특정 열을 기준으로 정렬
# ascending=False: 큰 값부터 작은 값 순서로 정렬

print("Top 5 students:")
print(sorted_df[["name", "class", "average_score"]].head())

print("\nBottom 5 students:")
print(sorted_df[["name", "class", "average_score"]].tail())
# head(): 위에서부터 5개 출력
# tail(): 아래에서부터 5개 출력
```

How to find top and bottom students

```
import pandas as pd

df = pd.read_csv("pandas_students_analysis.csv")

df["math"] = df["math"].fillna(df["math"].mean())
df["english"] = df["english"].fillna(df["english"].mean())
df["study_hours"] = df["study_hours"].fillna(df["study_hours"].mean())
df["attendance_rate"] = df["attendance_rate"].fillna(df["attendance_rate"].mean())

df["total_score"] = df["math"] + df["english"] + df["science"]
df["average_score"] = df["total_score"] / 3

sorted_df = df.sort_values("average_score", ascending=False)
# sort_values(): 특정 열을 기준으로 정렬
# ascending=False: 큰 값부터 작은 값 순서로 정렬

print("Top 5 students:")
print(sorted_df[["name", "class", "average_score"]].head())

print("\nBottom 5 students:")
print(sorted_df[["name", "class", "average_score"]].tail())
# head(): 위에서부터 5개 출력
# tail(): 아래에서부터 5개 출력
```

Let's make a simple report

```
import pandas as pd

df = pd.read_csv("pandas_students_analysis.csv")

df["math"] = df["math"].fillna(df["math"].mean())
df["english"] = df["english"].fillna(df["english"].mean())
df["study_hours"] = df["study_hours"].fillna(df["study_hours"].mean())
df["attendance_rate"] = df["attendance_rate"].fillna(df["attendance_rate"].mean())

df["total_score"] = df["math"] + df["english"] + df["science"]
df["average_score"] = df["total_score"] / 3
df["pass"] = df["average_score"] >= 80

best_student = df.loc[df["average_score"].idxmax()]
lowest_student = df.loc[df["average_score"].idxmin()]
best_class = df.groupby("class")["average_score"].mean().idxmax()
pass_rate = df["pass"].mean() * 100

print("Best student:", best_student["name"])
print("Lowest student:", lowest_student["name"])
print("Best class:", best_class)
print("Pass rate:", round(pass_rate, 2))
```


Problem : 학교 매점 판매 분석

학교 매점에서 하루 동안 판매된 주문 데이터가 CSV 파일로 주어진다.

pandas를 이용하여 매점 판매 데이터를 분석하고, 정해진 형식에 맞게 결과를 출력하시오.

조건

total_sales 열을 새로 만들어야 한다.

(total_sales = price * quantity)

학년별 주문 수량은 1학년, 2학년, 3학년 순서로 출력한다.

평균 만족도는 소수 둘째 자리까지 출력한다.

상위 3개 메뉴는 매출이 높은 순서대로 출력한다.

pandas만 사용한다.

출력

아래 내용을 순서대로 출력한다.

1. 전체 행 개수
2. 전체 열 개수
3. 전체 매출
4. 매출이 가장 높은 메뉴 이름과 매출
5. 평균 만족도가 가장 높은 카테고리과 평균 만족도
6. 학년별 주문 수량 합계
7. 만족도가 4 이상인 주문 개수
8. 매출 기준 상위 3개 메뉴와 매출

예제출력

```
ROWS 30
COLUMNS 10
TOTAL_SALES 111900
BEST_MENU 김밥 20000
BEST_CATEGORY drink 4.38
GRADE_QUANTITY
1 21
2 26
3 19
HIGH_SATISFACTION 24
TOP3_MENU
김밥 20000
떡볶이 18000
샌드위치 17500
```

CSV : school_store_sales.csv

Column	Meaning
order_id	주문 번호
student_id	학생 ID
grade	학년
menu	판매 메뉴
category	메뉴 종류
price	메뉴 1개 가격
quantity	주문 수량
satisfaction	만족도, 1~5
wait_minutes	대기 시간, 분